

**LAPORAN AKHIR
PEMROSESAN TEKS**

Menganalisis Tren Topik dalam Artikel



Oleh Kelompok 3:

- 1. Shafa Nasywa Dhiya : 22031554013**
- 2. Alivia Nayla Wibisono : 22031554041**
- 3. Ahmad fahim Nashikhul Umam : 22031554022**

**Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Negeri Surabaya
2022/2023**

BAB I

PENDAHULUAN

I. LATAR BELAKANG

Saat ini, banyak dokumen ilmiah yang dihasilkan oleh para peneliti, profesor, dan mahasiswa berbagai universitas di seluruh dunia, yang sering kali memuat materi penting dan bermanfaat dan diterbitkan di format tekstual. Karena jumlahnya yang semakin banyak artikel ilmiah dan sejumlah besar makalah yang diterbitkan, evaluasi dan review semua artikel dan ekstraksi informasi dan pengetahuan secara manual dari sejumlah besar teks ini terdapat tantangan dan bahkan mustahil. Namun, mengidentifikasi pola dan mengekstraksi pengetahuan potensial dalam tekstual dalam jumlah besar data merupakan isu penting dalam berbagai bidang keilmuan [1]

Teknologi yang terus berkembang dengan pesat serta hampir mempengaruhi segala aspek kehidupan manusia. Di era revolusi 4.0, muncul berbagai teknologi yang menggunakan sistem pembelajaran mesin (*Machine Learning*) untuk membantu manusia dalam mencari sesuatu secara tepat dan cepat [2]. Para peneliti, praktisi, perusahaan, dan pemangku kepentingan lainnya dalam dunia teknologi harus selalu up-to-date dengan perkembangan terbaru untuk menjaga daya saing, berinovasi, dan membuat keputusan yang informasi.

Tren teknologi mencakup berbagai hal, termasuk kemajuan dalam teknologi digital, kecerdasan buatan, pengembangan perangkat keras, penemuan dalam ilmu material, perkembangan perangkat lunak, dan banyak lagi. Dengan memahami tren tersebut, perhitungan atau pembobotan kata melalui teknik tokenisasi, stopwords, dan stemming, dan frekuensi munculnya kata dalam dokumen yang diberikan menunjukkan pentingnya kata itu di dalam sebuah dokumen [3] sehingga memudahkan peneliti untuk mengarahkan riset mereka ke arah yang paling relevan dan potensial untuk inovasi. Perusahaan dapat merencanakan strategi bisnis mereka berdasarkan tren ini dan menghindari keputusan yang kurang relevan. Selain itu, pemahaman tren teknologi juga berkontribusi pada kemampuan kolaborasi dan pertukaran pengetahuan antarpeneliti dan organisasi, yang akhirnya mempercepat perkembangan teknologi secara keseluruhan.

II. TUJUAN PENELITIAN

1. Menggunakan algoritma TF-IDF untuk mengekstrak kata kunci yang paling penting dalam teks/jurnal ilmiah, yang mencerminkan fokus dan topik utama dari setiap teks.
2. Berdasarkan hasil analisis TF-IDF, kita dapat mengelompokkan kata-kata dan frasa yang sering muncul bersama. Ini membantu dalam mengidentifikasi tema dan tren yang muncul dalam jurnal ilmiah. Pengelompokan ini dapat dilakukan dengan berbagai teknik seperti analisis kluster atau pemodelan topic. Proses ini memungkinkan kita untuk menggambarkan dan mengidentifikasi fokus penelitian yang dominan dalam literatur terkait.

BAB II

METODE

1. Pengumpulan Data: Data jurnal ilmiah dikumpulkan dan disimpan dalam format teks.
2. Preprocessing: Data jurnal diolah untuk membersihkan teks dari tanda baca, kata-kata berhenti, dan karakter khusus. Dokumen juga dipecah menjadi kalimat dan kata-kata.
3. Analisis TF-IDF: Setiap kata dalam dokumen diberi bobot menggunakan skema TF-IDF .
4. Clustering : Melakukan pengklasteran terhadap data yang sudah di ekstraksi fitur. Pengklasteran dilakukan menggunakan k-means.
5. Visualisasi: Hasil analisis ditampilkan dalam bentuk graphical user interface dan wordcloud agar memudahkan pembaca dalam memahami trend artikel.

BAB III

HASIL & ANALISIS

I.Pemahaman Data

Data yang diperoleh merupakan data yang bersumber dari situs kaggle. Data yang kami miliki berjumlah sekitar 5 juta data. Namun kami hanya menggunakan sebanyak 10 ribu data. Data tersebut merupakan data artikel internasional yang didalamnya terdapat 14 kolom, yaitu id, submitter, author, title, comments, journal-ref, doi, report-no, categories, license, abstract, versions, update-date, dan author-parsed. Untuk penelitian ini, kami hanya mengambil kolom title, abstract dan update-date yang kemudian kolom update-date nya dikonversi sehingga hanya tahun saja yang digunakan (update-year).

Tabel 1.1 Tahun dan Jumlah Artikelnya

2007	3111
2008	2069
2009	3040
2010	359
2011	324
2012	152
2013	82

2007	3111
2008	2069
2009	3040
2014	119
2015	303
2016	182
2017	46
2018	28
2019	129
2020	18
2021	14
2022	14
2023	10

Pada tabel 1.1 adalah jumlah artikel yang muncul pada 17 tahun terakhir dari dataset. yaitu pada tahun 2007 memiliki 3111 judul artikel, pada tahun 2008 memiliki 2069 judul artikel, pada tahun 2009 memiliki 3040 judul artikel, pada tahun 2010 memiliki 359 judul, tahun 2011 memiliki 324 judul, tahun 2012 memiliki 152 judul, tahun 2013 memiliki 82 judul, tahun 2014 memiliki 119 judul, tahun 2015 memiliki 303 judul, tahun 2016 memiliki 182 judul, tahun 2017 memiliki 46 judul, tahun 2018 memiliki 28 judul, tahun 2019 memiliki 129 judul, tahun 2020 memiliki 18 judul, tahun 2021 memiliki 14 judul, tahun 2022 memiliki 14 judul dan tahun 2023 memiliki 10 judul.

II. Pengolahan Data

1. Preprocessing

Sebelum melakukan analisis tren topik pada artikel, langkah pertama yang diterapkan adalah proses preprocessing data. Proses ini mencakup serangkaian tahapan untuk membersihkan dan mempersiapkan data teks agar dapat diolah secara efektif. Beberapa tahap preprocessing yang kami lakukan adalah memeriksa data apakah ada duplikat, memeriksa apakah ada nilai yang kosong, menghapus kolom yang tidak dibutuhkan, menghapus stopwords, stemming, dan lower casing.

2. Ekstraksi Fitur

Setelah tahap preprocessing, dilakukan ekstraksi fitur menggunakan metode TF-IDF. Tujuan dari langkah ini adalah untuk mengukur seberapa penting sebuah kata dalam

suatu dokumen dan seberapa unik kata tersebut dalam kumpulan dokumen secara keseluruhan. Beberapa langkah yang diambil dalam proses TF-IDF melibatkan:

a. vectorization

Mengonversi setiap dokumen teks menjadi vektor berdasarkan frekuensi kemunculan kata-kata. Kemudian menghitung TF (Term Frequency) yang merupakan jumlah kemunculan suatu kata dalam suatu dokumen.

b. IDF (Inverse Document Frequency):

Menghitung IDF yang mengukur seberapa unik sebuah kata di seluruh kumpulan dokumen. Kata-kata yang umum akan memiliki IDF yang rendah, sementara kata-kata yang lebih spesifik akan memiliki IDF yang tinggi.


c. TF-IDF Weighting

Menggabungkan nilai TF dan IDF untuk mendapatkan nilai bobot TF-IDF untuk setiap kata dalam setiap dokumen. Kata-kata dengan nilai TF-IDF tinggi menjadi representasi yang kuat dari konten dokumen.

berikut adalah informasi pada interval waktu beserta bobot TF-IDF masing-masing kata dan bentuk awan kata mereka. disini kami hanya menampilkan yang memiliki bobot kata-kata lebih dari 100 dan ditampilkan dalam wordcloud setiap interval waktu, yang ukurannya lebih besar setiap kata menunjukkan pentingnya kata itu. Untuk Misalnya kata effect dengan bobot 335 menunjukkan penerapan terbanyak pada cluster 0.


Tabel 2.1 wordcloud

cluster	kata penting dan bobotnya	wordcloud
0	product(105)energi(189)system(211)field(194)model(400)atom(102)quantum(460)properti(101)measur(161)decay(146)correl(110)struktur(123)effect(335)interact(161)phase(181)neutrino(101)state(254)scatter(104)teori(181)magnet(219)studi(123)transit(140)electron(132)latic(110)spin(181)dynam(205)optic(112)coupl(107)	
1	observ(127)cluster(162)star(221)galaxi(262)xray(105)	


2	gener(187)group(204)function(165)quantum(199)field(170)theori(230)space(188))problem(104)oper(107)algebra(193)solut(143)equat(207)complex(102)network(158)model(163)system(176)	 A word cloud of mathematical terms. The most prominent words are 'model', 'space', 'function', 'complex', 'algebra', 'equat', 'solut', 'quantum', 'field', 'theori', 'space', 'network', 'system', 'problem', 'oper', 'gener', 'algebra', 'equat', 'solut', 'quantum', 'field', 'theori', 'space', 'network', 'system', 'problem', 'oper', 'gener'. The words are in various colors (green, yellow, orange, red) and sizes, arranged in a somewhat circular pattern.
---	---	--

Beberapa contoh diagram lingkaran untuk visualisasi tren pada tahunnya.


a. tren pada tahun 2007




b. tren topik pada tahun 2008



c. tren topik pada tahun 2009



d. tern topik pada tahun 2010



3. Clustering

Clustering adalah suatu teknik dalam analisis data yang bertujuan untuk mengelompokkan data ke dalam kelompok atau klaster berdasarkan kemiripan antara data. Tujuan utama dari clustering adalah untuk mengidentifikasi struktur tersembunyi dalam data dan membuat pengelompokan yang bermakna berdasarkan propertinya. Metode clustering memungkinkan kita untuk menemukan pola alamiah dalam data tanpa adanya label atau anotasi sebelumnya.

K-Means adalah algoritma clustering yang digunakan untuk mengelompokkan data ke dalam beberapa klaster berdasarkan kemiripan atribut. Tujuan utama K-Means adalah meminimalkan varians intra-klaster dan memaksimalkan varians antara klaster.


disini kami mengelompokkan menjadi 3 cluster sebagaimana tabel berikut:

Tabel 3.1 cluster

cluster	jumlah pada cluster
---------	---------------------


0	4510
1	1419
2	4071

pada tabel 3.1 menjelaskan bahwa cluster 0 memiliki 4510 jumlah artikel, cluster 1 memiliki 1419 jumlah artikel, cluster 2 memiliki 4071 jumlah artikel. dengan diagram batang sebagai berikut:



Gambar 1.1 Diagram batang cluster

4. Silhouette Scor Distribution



Gambar 1.2 grafik skor Silhouette

sebagaimana pada gambar 1.2 kami juga menghitung dan memvisualisasikan skor Silhouette untuk evaluasi kualitas klustering. Skor Silhouette mengukur seberapa baik setiap data berada dalam klasternya sendiri jika dibandingkan dengan klaster tetangganya. Skor ini berkisar dari -1 hingga 1, di mana nilai tinggi menunjukkan bahwa data tersebut ditempatkan dengan baik di dalam klasternya dan secara relatif terpisah dari klaster tetangganya. berdasarkan hasil skornya kami memperoleh hasil sebagai berikut.

Tabel 4.1 Silhouette Score

Cluster	Silhouette Score
0	0.0030200195356728694
1	0.015141409552114586
2	0.0028383408608316186
AVG	0.004666083390478076

4. Davies-Bouldin-Indeks

merupakan suatu metrik evaluasi untuk model klustering, khususnya hasil klustering yang dihasilkan oleh algoritma KMeans pada data teks. Davies-Bouldin Index mengukur seberapa baik pembagian klaster terhadap data dan seberapa besar pemisahan antara klaster. Semakin rendah nilai Davies-Bouldin Index, semakin baik hasil klusteringnya. Davies-Bouldin Index memberikan informasi tentang seberapa baik klustering telah dilakukan. dengan pemisahan yang lebih jelas

antar kluster. Sebaliknya, nilai yang lebih tinggi dapat mengindikasikan bahwa klastering kurang baik. dan dari hasil Davies-Bouldin-Indeks dari proyek kami adalah berjumlah 13.475784046594464.

5. GUI

.....

III. Diskusi

Proyek ini menghadirkan sumbangan signifikan dalam pemahaman tren riset dengan menyatukan teknik-teknik analisis kunci, seperti Pemrosesan Bahasa Alami (NLP), klastering menggunakan KMeans, dan visualisasi. Integrasi ketiga elemen ini memberikan landasan yang kuat untuk menggali wawasan mendalam dari judul-judul teks/jurnal ilmiah.

Antarmuka pengguna yang dibangun menunjukkan upaya untuk memberikan aksesibilitas dan keterbacaan data kepada pengguna. Fleksibilitas dalam mengeksplorasi tren berdasarkan tahun memberikan keleluasaan kepada pengguna untuk mendapatkan pemahaman yang lebih kontekstual terhadap perkembangan riset dari waktu ke waktu.

Namun demikian, proyek ini tidak terlepas dari keterbatasan tertentu. Pertama-tama, ukuran kluster dan parameter algoritma KMeans dapat menjadi subjek optimasi lebih lanjut untuk memastikan hasil klastering yang lebih optimal. Penggunaan metode analisis tambahan, seperti analisis sentimen atau korelasi antarkluster, dapat menjadi langkah lanjutan untuk mendapatkan perspektif yang lebih komprehensif.

Dalam upaya untuk meningkatkan keberagaman fitur, penambahan elemen analisis seperti ekstraksi fitur lebih lanjut atau penggunaan model pembelajaran mesin dapat menjadi langkah-langkah selanjutnya. Hal ini akan membuka peluang untuk mengeksplorasi kompleksitas lebih lanjut dari setiap judul penelitian, menghasilkan pemahaman yang lebih dalam.

Secara keseluruhan, proyek ini menciptakan fondasi yang solid untuk analisis tren penelitian dan memberikan landasan untuk pengembangan lebih lanjut. Penelitian masa depan dapat fokus pada pengembangan alat analisis yang lebih canggih, penggunaan teknik pembelajaran mesin lanjutan, dan integrasi fitur-fitur baru untuk memberikan wawasan yang lebih kaya dan kontekstual dalam dunia riset dan penelitian.

BAB IV

KESIMPULAN

Proyek ini berhasil mengimplementasikan teknik Pemrosesan Bahasa Alami (NLP), klastering dengan algoritma KMeans, dan visualisasi untuk menganalisis tren dalam judul-judul

teks/jurnal ilmiah. Antarmuka pengguna yang disediakan memberikan aksesibilitas yang baik bagi pengguna untuk mengeksplorasi tren berdasarkan tahun.

Hasil analisis klustering memungkinkan identifikasi kelompok kata kunci yang muncul bersama dalam judul-judul penelitian, memberikan pemahaman mendalam tentang fokus riset pada periode waktu tertentu. Selain itu, visualisasi menggunakan WordCloud menambahkan dimensi ekstra untuk menyajikan kata-kata kunci.

Keterbatasan proyek meliputi ukuran klaster yang mungkin memerlukan optimasi lebih lanjut, dan pengembangan fitur tambahan dapat memberikan analisis yang lebih komprehensif. Meskipun demikian, proyek ini memberikan landasan yang solid untuk analisis tren penelitian dan memberikan gambaran tentang potensi riset lebih lanjut.

Kesimpulannya, proyek ini sukses dalam memberikan kontribusi pada pemahaman tren dalam dunia penelitian, dan pengembangan lebih lanjut dapat menghasilkan alat analisis yang semakin canggih dan informatif. Dengan menggunakan teknologi seperti NLP, klustering, dan visualisasi, proyek ini membuka pintu bagi penelitian lanjutan dalam memahami evolusi pengetahuan di berbagai disiplin ilmu.

BAB V

REFERENSI

1. Dastani M, Chelak A M, Ziaei S. Identifying Emerging Trends in Scientific Texts Using TF-IDF Algorithm: A Case Study of Medical Librarianship and Information Articles. *Health Tech Asmnt Act.* 4(2).e6231. doi: 10.18502/htaa.v4i2.6231.
2. Supardi C F. (2023).Sistem pencarian Tren Judul Tugas Akhir Mahasiswa Teknik Informatika UNISSULA Menggunakan Metode Keyword Extraction. Universitas Islam Sultan Agung Semarang
3. Rofiqi M A, Fauzan A C, Agustin A P, Saputra A A, Fahma H D. Implementasi *Term-Frequency Inverse Document Frequency(TF-IDF)* Untuk Mencari Relevansi Dokumen Berdasarkan *Query*. *ILKOMNIKA: Journal of Computer Science and Applied Informatics*. Vol. 1, No. 2, Desember 2019, Halaman 58-64