





ANALISIS TREND TOPIK PADA ARTIKEL

Disusun Oleh : Kelompok 3
2022 B





PENDAHULUAN

Pada era Globalisasi ini, kita sudah memasuki era yang sangat kuat hubungannya dengan teknologi. Para peneliti, praktisi, perusahaan, dan pemangku kepentingan lainnya dalam dunia teknologi harus selalu up-to-date dengan perkembangan terbaru untuk menjaga daya saing, berinovasi, dan membuat keputusan yang informatif.

Tren teknologi mencakup berbagai hal, termasuk kemajuan dalam teknologi digital, kecerdasan buatan, pengembangan perangkat keras, penemuan dalam ilmu material, perkembangan perangkat lunak, dan banyak lagi. Dengan memahami tren tersebut, peneliti dapat mengarahkan riset mereka ke arah yang paling relevan dan potensial untuk inovasi. Perusahaan dapat merencanakan strategi bisnis mereka berdasarkan tren ini dan menghindari keputusan yang kurang relevan.



meet our team



Alivia Nayla




Shafa Nasywa



Ahmad Fahim



TENTANG PROJECT



Kami membuat project menganalisis trend topik pada artikel. Data yang kami dapatkan bersumber dari situs kaggle dengan jumlah sebanyak 5 juta data dalam bentuk json yang kemudian kami potong menjadi 10 ribu dan dibuat dalam bentuk xlxs.


Setelah mendapatkan datanya kami melakukan preprocessing, ekstraksi fitur, kemudian clustering. Untuk clustering yang kami gunakan adalah k-means. Setelahnya kami membuat program Graphical User Interface.



ISI PRESENTASI

- 1 Perkenalan Kelompok
- 2 Pendahuluan
- 3 Pembahasan
- 4 Kesimpulan
- 5 Penutup





Pembahasan

Berupa step-step yang telah dilakukan



DATA CLEANSING

```
1  #load data
2  data = pd.read_excel('/content/output.xlsx', engine='openpyxl')
3
4  #cek duplikat
5  data.duplicated()
6
7  #hitung jumlah duplikat row
8  data.duplicated().sum()
9
10 #cek missing value
11 data.isnull()
12
13 #hitung missing value di kolom
14 data.isnull().sum()
15
16 #drop duplikat
17 data.drop_duplicates(inplace=True)
18
19 #remove kolom yg gak dibuthkan
20 columns_to_remove = ['id', 'submitter', 'authors', 'comments', 'journal-ref', 'doi', 'report-no', 'update_date',
21                      'categories', 'license', 'versions', 'authors_parsed']
22
23 #drop kolom yg gk dibutuhin
24 data.drop(columns=columns_to_remove, inplace=True)
25
26 #save data bersih
27 data.to_excel('datedel.xlsx', index=False)
28
```


journal-ref	doi	report-no	categories	license	abstract	versions	update_date	authors_parsed
arXiv:0710.3432	10.1103/PhysRevD.76.013009	ANL-HEP-PR-07-12	hep-ph	NaN	A fully differential calculation in perturbation theory	[{'version': 'v1', 'created': 'Mon, 2 Apr 2007...'}]	2008-11-26	[['Balázs', 'C.'], ['Berger', 'E. L.']]

```
data.isnull()
data.isnull().sum()
data.isnull()
```

	id	submitter	authors	title	comments	journal-ref	doi	report-no	categories	license	abstract	versions	update_date	authors_parsed
0	False	False	False	False	False	False	False	False	False	True	False	False	False	False

PRE- PROCESSING NORMALISASI

```
1 import pandas as pd
2 import re
3 import nltk
4 from nltk.corpus import stopwords
5 from nltk.stem import PorterStemmer
6 from nltk.tokenize import word_tokenize
7
8 #load data yg udh dibersihin
9 file_path = '/content/datedel.xlsx'
10 df = pd.read_excel(file_path)
11
12 #function buat normalisasi
13 def normalize_text(text):
14     #remove non alfabet
15     text = re.sub(r'^a-zA-Z\s', '', text)
16
17     #lowercasting
18     text = text.lower()
19
20     #hapus stop word
21     stop_words = set(stopwords.words('english'))
22     words = word_tokenize(text)
23     filtered_text = [word for word in words if word.lower() not in stop_words]
24
25     #stemming
26     ps = PorterStemmer()
27     stemmed_text = [ps.stem(word) for word in filtered_text]
28
29     #join the stemmed words back into text
30     normalized_text = ' '.join(stemmed_text)
31
32     return normalized_text
33
34 #apply text normalisasi ke kolom 'title'
35 df['title'] = df['title'].apply(normalize_text)
36
37 #apply text normalisasi ke kolom 'abstract'
38 df['abstract'] = df['abstract'].apply(normalize_text)
39
40 #save normalisasi ke excel
41 output_file_path = 'normalization.xlsx'
42 df.to_excel(output_file_path, index=False)
```

DATA SEBELUM

```
data = pd.read_excel('/content/output.xlsx', engine='openpyxl')
data
```

journal-ref	doi	report-no	categories	license	abstract	versions	update_date	authors_parsed
hep-th/0705340,2007	10.1103/PhysRevD.76.013009	ANL-HEP-PR-07-12	hep-ph	NaN	A fully differential calculation in perturbation theory	[{'version': 'v1', 'created': 'Mon, 2 Apr 2007...'}]	2008-11-26	[['Balázs', 'C.'], ['Berger', 'E. L.'], ...]
NaN	NaN	NaN	math.CO cs.CG	http://arxiv.org/licenses/nonexclusive-distrib...	We describe a new algorithm, the (k, ℓ) -...	[{'version': 'v1', 'created': 'Sat, 31 Mar 2008...'}]	2008-12-13	[['Streinu', 'Illeana'], ['Theran', 'Louis'], ...]
NaN	NaN	NaN	physics.gen-ph	NaN	The evolution of Earth-Moon system is described by...	[{'version': 'v1', 'created': 'Sun, 1 Apr 2007...'}]	2008-01-13	[['Pan', 'Hongjun'], ...]

HASIL NORMALISASI

	title	abstract	update_year
0	calcul prompt diphoton product cross section t...	fulli differenti calcul perturb quantum chromo...	2008
1	sparsitycertifi graph decomposit	describ new algorithm kellpebbi game color use...	2008
2	evolut earthmoon system base dark matter field...	evolut earthmoon system describ dark matter fi...	2008
3	determin stirl cycl number count unlabel acycl...	show determin stirl cycl number count unlabel ...	2007
4	dyadic lambdaalpha lambdaalpha	paper show comput lambdaalpha norm alphag use ...	2013
...	...	...	...
9995	superconduct behavior solid solut ypdxptxge	compound ypdge earlier report us one ternari s...	2009
9996	geomet toolkit string compactif	lectur note meant serv introduct geometr const...	2009
9997	compactifi moduli project bundl	present method compactifi stack pglIntorsor azu...	2018
9998	entrelac dalgebr de lie wreath product lie alg...	full detail given definit construct wreath pro...	2007
9999	nonuniqu ergod observ topolog dual algebra lam...	continu articl studi lamin dual small action f...	2010

10000 rows × 3 columns

TF-IDF


```
1 import pandas as pd
2 import re
3 import string
4 from sklearn.feature_extraction.text import TfidfVectorizer
5
6 #membaca data yg sdh dinormalisasi
7 df = pd.read_excel('/content/normalization.xlsx')
8
9 #asumsikan 'abstract' kolom yg berisi data text
10 all_text = df['abstract'].astype(str).tolist()
11
12 #preprocessing dan tokenizing
13 def preprocessing(line):
14     line = line.lower()
15     line = re.sub(r"[{}]" .format(string.punctuation), " ", line)
16     return line
17
18 #apply preprocessing untuk setiap text line
19 all_text = [preprocessing(line) for line in all_text]
20
21 #TF-IDF vectorization
22 vectorizer = TfidfVectorizer(stop_words='english')
23 X = vectorizer.fit_transform(all_text)
24
25 #convert TF-IDF matrix to a df
26 tfidf_df = pd.DataFrame(X.toarray(), columns=vectorizer.get_feature_names_out())
27
28 #concatenate TF-IDF df dgn og df
29 result_df = pd.concat([df, tfidf_df], axis=1)
30
31 #display df
32 print(result_df.head())
```


K-MEANS CLUSTERING

```
1 import pandas as pd
2 from sklearn.cluster import KMeans
3 from sklearn.feature_extraction.text import TfidfVectorizer
4
5 #baca data yg udh dinormalisasi
6 df = pd.read_excel('/content/normalization.xlsx')
7
8 #asumsuikan 'abstract' data text
9 all_text = df['abstract'].astype(str).tolist()
10
11 #TF-IDF vectorization
12 vectorizer = TfidfVectorizer(stop_words='english')
13 X = vectorizer.fit_transform(all_text)
14
15 #set optimal number buat clusters (k)
16 #metode untuk determining k pake silhouette score
17 k = 3
18
19 #apply kmeans clustering
20 kmeans = KMeans(n_clusters=k, random_state=42)
21 kmeans.fit(X)
22
23 #tambah cluster label ke df
24 df['cluster'] = kmeans.labels_
25
26 #save df ke excel dgn klaster lebel
27 output_path = '/content/clustered.xlsx'
28 df.to_excel(output_path, index=False)
```


LABEL CLUSTER 'O'

WordCloud for Cluster 0





LABEL CLUSTER '2'

WordCloud for Cluster 2





EVALUASI MATRIX

```
1  from sklearn.metrics import silhouette_score, davies_bouldin_score
2  import seaborn as sns
3
4  #asumsikan 'X' adalah TF-IDF matrix obtained dari step sebelumnya
5
6  #fit kmeans model
7  kmeans = KMeans(n_clusters=k, random_state=42)
8  kmeans.fit(X)
9
10 #silhouette score
11 silhouette_avg = silhouette_score(X, kmeans.labels_)
12
13 print("Silhouette Score: ", silhouette_avg)
14
15 #individual silhouette scores untuk setiap data point
16 silhouette_scores = silhouette_samples(X, kmeans.labels_)
17
18 #add silhouette scores ke df
19 df['Silhouette Score'] = silhouette_scores
20
21 #display silhouette score distribution
22 plt.figure(figsize=(8, 6))
23 sns.histplot(df['Silhouette Score'], bins=20, kde=True)
24 plt.title('Silhouette Score Distribution')
25 plt.xlabel('Silhouette Score')
26 plt.ylabel('Frequency')
27 plt.show()
28
29 #davies-bouldin index
30 davies_bouldin = davies_bouldin_score(X.toarray(), kmeans.labels_)
31
32 print("Davies-Bouldin Index:", davies_bouldin)
```

KESIMPULAN

Dalam project ini, kami telah berhasil melewati beberapa langkah, dimulai dari preprocessing dan normalisasi data untuk memastikan kualitas data yang optimal. Selanjutnya, dilakukan ekstraksi fitur untuk mengekstrak informasi yang relevan dari dataset.

Hasilnya, kami mencapai siluete score sebesar 0,463 dan indeks Davies-Bouldin sebesar 13,46. Siluete score mengindikasikan sejauh mana objek dalam sebuah cluster mirip satu sama lain dan berbeda dari cluster lainnya. Semakin tinggi nilai silueta score, semakin baik kualitas clusteringnya. Sementara itu, indeks Davies-Bouldin mengukur seberapa baik objek dalam suatu cluster berdekatan dan seberapa jauh cluster satu sama lain. Semakin rendah nilai davies-bouldinnya semakin baik pemisahan antar clusternya.



KONTRIBUSI ANGGOTA

1. Shafa Nasywa Dhiya: Tf-IDF, Evaluasi Matrix, Graphical User Interface window 1, menggabungkan GUI 1-3, membuat wordcloud
2. Alivia Nayla Wibisono: Cut data, Clusttering, Graphical User Interface windows 3, preprocessing
3. Ahmad Fahim: Data Cleansing, full laporan, Graphical User Interface window 2





Terima Kasih